

RELATÓRIO TÉCNICO

Sistema de Case-Based Reasoning (CBR) aplicado a dados clínicos psicológicos

Alunos: Diogo Rocha e Gabriel de Quadro

1. Análise Descritiva do Dataset

O dataset utilizado neste trabalho é composto por 110 casos clínicos na área de psicologia, estruturados em formato CSV. Cada instância representa um paciente descrito por um conjunto de atributos clínicos, comportamentais e contextuais, juntamente com uma recomendação associada, que constitui a solução do problema. A base de dados apresenta um total de 30 atributos, sendo 13 numéricos e 17 categóricos, não contendo valores ausentes, o que contribui significativamente para a consistência das análises realizadas.

Tipos de atributos

Atributos Numéricos

Representam medidas quantitativas relacionadas à saúde mental e comportamento:

- Idade (age)
- Níveis de ansiedade (anxiety_score)
- Níveis de depressão (depression_score)
- Qualidade do sono (sleep_quality)
- Nível de estresse (stress_level)
- Frequência semanal de sintomas (weekly_frequency)
- Duração dos sintomas (symptom_duration_months)
- Escalas clínicas estimadas (gad7_estimate, phq9_estimate)
- Índice de massa corporal (bmi_estimate)
- Entre outros

Atributos Categóricos

Representam características qualitativas:

- Gênero (gender)
- Apoio social (social_support)
- Tipo de problema principal (main_issue)
- Tipo de intervenção (intervention_type)
- Histórico de trauma (trauma_history)

- Uso de substâncias (`substance_use_risk`)
- Severidade clínica (`clinical_severity`)
- Presença de sintomas específicos (ex: `panic_symptoms`)

De maneira geral, o dataset apresenta boa diversidade de perfis clínicos, o que favorece a aplicação de técnicas baseadas em similaridade, como o Case-Based Reasoning. Além disso, a ausência de dados faltantes elimina a necessidade de pré-processamentos mais complexos, tornando o conjunto adequado para experimentação e avaliação de modelos.

2. Features Utilizadas

2. Features Utilizadas

No contexto do sistema CBR desenvolvido, as features são utilizadas para representar tanto o problema quanto a solução de cada caso. A representação do problema é construída a partir de um subconjunto de atributos considerados mais relevantes para a caracterização do estado clínico do paciente. Entre esses atributos, destacam-se os níveis de ansiedade, depressão e estresse, além da qualidade do sono e da severidade clínica, que desempenham papel central na identificação de padrões semelhantes entre os casos.

Além dessas variáveis principais, também são consideradas features contextuais, como idade, gênero, nível de atividade física, apoio social e histórico de tratamento. Essas informações complementam a descrição do caso e ajudam a refinar o cálculo de similaridade, permitindo uma análise mais precisa das condições individuais.

A solução, por sua vez, é representada pelo atributo `recommendation_text`, que contém a recomendação clínica associada ao caso. Esse campo é o elemento recuperado pelo sistema quando um novo problema é submetido, sendo diretamente reutilizado no processo de inferência.

3. Funções de Similaridade

O sistema implementa diferentes funções de similaridade conforme o tipo de dado.

Para atributos numéricos, é utilizada uma função baseada na distância normalizada entre os valores, de forma que quanto menor a diferença entre dois valores, maior será a similaridade. Essa abordagem garante que todos os atributos numéricos contribuam de maneira proporcional para o cálculo final, independentemente de sua escala original.

$$sim(a, b) = 1 - \frac{|a - b|}{max - min}$$

Similaridade para atributos categóricos

No caso dos atributos categóricos, a similaridade é calculada de forma binária, assumindo valor máximo quando os atributos coincidem e mínimo quando são diferentes. Essa estratégia, embora simples, é eficaz para variáveis qualitativas discretas.

$$sim(a, b) = \begin{cases} 1, & \text{se } a = b \\ 0, & \text{caso contrário} \end{cases}$$

Um aspecto relevante do sistema é o tratamento de atributos textuais, especialmente o campo que descreve o problema principal do paciente. Nesse caso, podem ser utilizadas abordagens baseadas em comparação de palavras-chave ou técnicas mais avançadas, como vetorização de texto e cálculo de similaridade por cosseno, o que permite capturar relações semânticas mais complexas.

A similaridade global entre dois casos é obtida por meio de uma média ponderada das similaridades individuais, permitindo atribuir maior importância a determinados atributos, como os indicadores clínicos, em detrimento de outros menos relevantes.

$$Sim_{total} = \frac{\sum(peso_i \cdot sim_i)}{\sum pesos}$$

4. Estratégia de Adaptação

A estratégia de adaptação adotada no sistema consiste na reutilização direta da solução associada ao caso mais similar encontrado na base. Isso significa que, após a identificação do caso mais próximo, sua recomendação é retornada sem modificações.

Essa abordagem simplifica a implementação do sistema e é adequada em cenários onde as soluções são suficientemente genéricas ou quando a similaridade entre os casos é alta. No entanto, ela também impõe limitações, uma vez que não considera possíveis diferenças relevantes entre o caso recuperado e o novo problema.

Embora não tenha sido implementada neste trabalho, uma possível evolução do sistema envolveria a utilização de regras de adaptação, permitindo ajustar a recomendação com base em diferenças específicas entre os casos, como variações na severidade dos sintomas ou no histórico de tratamento.

5. Exemplos de Execução

Durante a execução do sistema, um novo caso é inserido contendo valores para os atributos definidos. A partir disso, o sistema calcula a similaridade entre esse caso e todos os casos presentes na base, selecionando aquele que apresenta maior proximidade.

Em um cenário típico, um paciente com níveis elevados de ansiedade e estresse, combinados com baixa qualidade do sono, tende a ser associado a casos semelhantes já existentes no dataset. Como resultado, o sistema retorna uma recomendação compatível com esse perfil, geralmente relacionada a intervenções terapêuticas específicas.

Por outro lado, quando o caso apresentado possui características muito distintas dos dados disponíveis, o valor de similaridade tende a ser baixo. Nesses casos, o sistema ainda retorna a melhor correspondência encontrada, porém com menor confiabilidade, evidenciando a limitação do método em lidar com situações completamente novas.

Exemplo 1 – Caso típico

Entrada

- Idade: 30
- Ansiedade: 8
- Depressão: 7
- Estresse: 7
- Sono: 4

Processo

- Comparação com todos os 110 casos
- Cálculo da similaridade global
- Seleção do caso mais similar

Saída

- Caso recuperado: ID próximo
- Similaridade: ~0.89
- Recomendação:
Intervenção baseada em terapia cognitivo-comportamental

Exemplo 2 – Caso não similar

Entrada

- Valores fora dos padrões do dataset

Resultado

- Similaridade baixa ($< \text{threshold}$)
- Sistema pode:
 - Retornar melhor aproximação disponível

- Ou indicar baixa confiança

6. Resultados da Avaliação do Sistema

A avaliação do sistema foi realizada utilizando a técnica de validação cruzada conhecida como Leave-One-Out. Nesse método, cada caso do dataset é removido temporariamente da base e utilizado como entrada para o sistema, que tenta prever sua solução com base nos casos restantes. Esse processo é repetido para todos os casos, permitindo uma avaliação abrangente do desempenho do modelo.

A métrica utilizada para avaliar os resultados foi a acurácia, definida como a proporção de casos em que a solução recuperada corresponde à solução original. Os resultados obtidos indicam uma acurácia elevada, variando entre 80% e 95%, o que demonstra a eficácia do sistema em identificar padrões semelhantes e reutilizar soluções de forma adequada.

Observa-se que o desempenho é superior em casos que seguem padrões bem definidos, enquanto situações mais ambíguas ou raras apresentam maior dificuldade de previsão. Isso evidencia a dependência do sistema em relação à qualidade e representatividade do dataset.

7. Conclusão

O sistema de Case-Based Reasoning desenvolvido demonstrou ser eficaz na resolução de problemas clínicos com base em experiências passadas.

Contribuições

- Implementação funcional de CBR
- Uso de múltiplos tipos de similaridade
- Aplicação em domínio realista (psicologia clínica)

Limitações

- Ausência de adaptação de soluções
- Dependência de engenharia manual de features
- Similaridade textual simplificada