

Trabalho Prático:

Algoritmos de Clustering

1. Introdução e Definição do Problema

Este trabalho tem como objetivo aplicar algoritmos de clustering não supervisionado sobre o dataset Pima Indians Diabetes Database, um conjunto de dados amplamente utilizado na literatura de aprendizado de máquina aplicado à saúde. O dataset foi originalmente utilizado por Smith et al. (1988) no estudo "Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus", publicado no Proceedings of the Annual Symposium on Computer Application in Medical Care.

Problema definido: Verificar se os dados de pacientes do sexo feminino com herança indígena Pima formam agrupamentos naturais que correspondam ao perfil de risco para diabetes — em especial, identificar se existe separação entre pacientes jovens (sem histórico de risco) e pacientes mais velhos com indicadores metabólicos elevados (glicose, IMC, insulina), e se esses agrupamentos coincidem com os diagnósticos reais de diabetes.

2. Descrição do Dataset

O dataset contém 768 instâncias e 9 atributos, todos numéricos. A variável alvo Outcome indica se a paciente desenvolveu diabetes (1) ou não (0) nos 5 anos seguintes ao exame. Esta coluna foi **removida antes da clusterização** e utilizada apenas para avaliação posterior dos clusters encontrados.

Pregnancies	Número de gestações	Inteiro
Glucose	Concentração de glicose (mg/dL)	Inteiro
BloodPressure	Pressão arterial diastólica (mmHg)	Inteiro
SkinThickness	Espessura da dobra cutânea (mm)	Inteiro
Insulin	Insulina sérica 2h após teste (μU/mL)	Inteiro
BMI	Índice de massa corporal (kg/m²)	Float
DiabetesPedigreeFunction	Função de histórico familiar de diabetes	Float
Age	Idade (anos)	Inteiro
Outcome	Diagnóstico de diabetes (0=não, 1=sim)	Binário

3. Análise Descritiva

3.1 Análise Univariada

A tabela abaixo apresenta as estatísticas descritivas das 8 variáveis preditoras. Destaca-se que colunas como Glucose, Insulin e BMI possuem zeros biologicamente impossíveis, indicando valores faltantes codificados como zero — tratados na etapa de pré-processamento.

Pregnancies	3.85	3.37	0.00	1.00	3.00	6.00	17.00
Glucose	120.89	31.97	0.00	99.00	117.00	140.25	199.00
BloodPressure	69.11	19.36	0.00	62.00	72.00	80.00	122.00
SkinThickness	20.54	15.95	0.00	0.00	23.00	32.00	99.00
Insulin	79.80	115.24	0.00	0.00	30.50	127.25	846.00
BMI	31.99	7.88	0.00	27.30	32.00	36.60	67.10
DiabetesPedigreeFunction	0.47	0.33	0.08	0.24	0.37	0.63	2.42
Age	33.24	11.76	21.00	24.00	29.00	41.00	81.00




Figura 1 — Histogramas das variáveis preditoras.




Figura 2 — Boxplots evidenciando outliers em Insulin, Glucose e Age.

3.2 Análise Bivariada

A correlação de Pearson revela que as maiores associações são entre Pregnancies e Age ($r=0.54$), SkinThickness e Insulin ($r=0.44$), e SkinThickness e BMI ($r=0.39$). Essas correlações sugerem que variáveis metabólicas tendem a crescer juntas, o que pode facilitar a formação de clusters por perfil de risco.




Figura 3 — Matriz de dispersão entre pares de variáveis (amostra de 200 instâncias).

3.3 Análise Multivariada




Figura 4 — Heatmap de correlação de Pearson entre todas as variáveis.

A análise de componentes principais (PCA) mostra que os primeiros 5 componentes explicam 81,2% da variância total dos dados, sendo que os dois primeiros acumulam 47,8%. Esse resultado justifica o uso de PCA 2D para visualização dos clusters.




Figura 5 — Variância explicada por componente principal.

4. Pré-processamento

As etapas de pré-processamento foram realizadas na seguinte ordem:

Remoção do rótulo	Coluna Outcome remov

Substituição de zeros	Zeros em Glucose, BloodPressure, Skin pela mediana da
Tratamento de outliers	Clipping IQR (1.5x): valores abaixo de foram limitados BloodPressure: 45
Verificação de NaN	Confirmado 0 valores faltantes após anteriores
Normalização	StandardScaler aplicado (média=0, de
PCA 2D	Redução para 2 componentes p

5. Algoritmos de Clustering e Resultados

5.1 K-Means

O K-Means foi testado com $k=2$, $k=3$ e $k=4$, utilizando inicialização k-means++ e 20 reinicializações aleatórias para maior estabilidade. O melhor resultado foi obtido com $k=2$ (Silhouette=0.1775), que divide os pacientes em dois grupos principais: um grupo de baixo risco (glicose e IMC menores) e um de alto risco metabólico.




Figura 6 — K-Means com $k=2$, 3 e 4 visualizados no espaço PCA.

5.2 Agglomerative Clustering

O clustering hierárquico aglomerativo foi testado com $k=2$ e $k=3$ combinados com três métodos de linkage: ward, complete e average. O linkage average com $k=2$ obteve o melhor Silhouette Score (0.2374) e o menor Davies-Bouldin (0.8365), porém forma clusters muito desbalanceados (um cluster com quase todos os pontos e outro com poucos). O linkage ward com $k=2$ oferece clusters mais equilibrados e interpretáveis.




Figura 7 — Agglomerative Clustering com diferentes linkages e k visualizados no espaço PCA.

5.3 DBSCAN

O DBSCAN foi testado com diferentes combinações de eps e min_samples. Com eps muito pequeno (0.5 e 0.7), todos os pontos foram classificados como ruído, indicando que a densidade do dataset normalizado é baixa nessa escala. Com eps=1.0 e min_samples=10, o algoritmo encontrou 2 clusters com 724 pontos de ruído, mas obteve o melhor Silhouette Score geral do trabalho (0.2944), indicando que os clusters densos encontrados são bem separados — embora cubram apenas parte dos dados.




Figura 8 — DBSCAN com diferentes eps e min_samples visualizados no espaço PCA.

6. Métricas de Avaliação e Comparação

Os algoritmos foram comparados com três métricas internas: Silhouette Score (maior = melhor, máximo 1.0), Davies-Bouldin Index (menor = melhor, mínimo 0.0) e Calinski-Harabasz Score (maior = melhor). Configurações do DBSCAN com 0 clusters válidos foram omitidas.

K-Means	k=2	0.1775	1.8943	189.88
K-Means	k=3	0.1773	1.8705	168.42
K-Means	k=4	0.1373	1.8913	139.09
Agglomerative	k=2, linkage=ward	0.1369	2.0376	136.91
Agglomerative	k=2, linkage=complete	0.1385	2.2756	108.68
Agglomerative	k=2, linkage=average	0.2374	0.8365	4.66
Agglomerative	k=3, linkage=ward	0.1120	2.2604	113.97
Agglomerative	k=3, linkage=complete	0.1104	2.3442	103.54
Agglomerative	k=3, linkage=average	0.1429	0.7668	3.51
DBSCAN	eps=1.0, min_samples=5	0.1752	1.0312	20.45
DBSCAN	eps=1.0, min_samples=10	0.2944	1.1294	17.37

Tabela 2 — Métricas de avaliação. Linhas destacadas = melhores por métrica.



Figura 9 — Rótulos originais (Outcome) no espaço PCA para comparação visual com os clusters.

7. Discussão dos Resultados

Qualidade geral dos clusters:

Os valores de Silhouette Score ficaram entre 0.11 e 0.29, o que indica clusters moderadamente separados mas com sobreposição considerável. Isso é esperado para dados clínicos reais, onde não existe separação natural bem definida entre grupos de pacientes diabéticos e não diabéticos com base apenas em medidas clínicas.

Comparação entre algoritmos:

O K-Means com $k=2$ e $k=3$ produziu os clusters mais equilibrados e com bom Calinski-Harabasz Score (189.88), indicando clusters compactos e bem separados em termos de variância interna. O Agglomerative com $\text{linkage}=\text{average}$ gerou o melhor Silhouette (0.2374) e menor Davies-Bouldin (0.8365), porém os clusters são extremamente desbalanceados — quase todos os pontos ficam em um único cluster, o que limita sua interpretabilidade. O DBSCAN com $\text{eps}=1.0$, $\text{min_samples}=10$ encontrou os clusters mais puros (Silhouette=0.2944), mas classificou 94% dos dados como ruído, tornando-o pouco útil para este dataset de densidade uniforme.

Interpretação clínica:

Comparando os clusters do K-Means $k=2$ com os rótulos originais (Figura 9), observa-se que os clusters encontrados têm uma correspondência parcial com o diagnóstico de diabetes: o cluster de maior concentração nas regiões superiores do espaço PCA tende a incluir mais pacientes diabéticos, enquanto o cluster inferior agrupa majoritariamente pacientes não diabéticos. Isso confirma a hipótese inicial de que variáveis como Glucose, BMI e Age são suficientes para detectar grupos de risco, mesmo sem usar o rótulo.

Limitações:

O dataset possui apenas 768 instâncias e o pré-processamento de zeros por mediana pode ter suavizado diferenças importantes entre grupos. O DBSCAN mostrou-se inadequado para este dataset por sua distribuição uniforme no espaço normalizado. Para trabalhos futuros, recomenda-se testar t-SNE ou UMAP para redução dimensional e algoritmos como Gaussian Mixture Models para modelagem probabilística dos clusters.

8. Conclusão

Este trabalho aplicou três algoritmos de clustering (K-Means, Agglomerative e DBSCAN) sobre o dataset Pima Indians Diabetes após análise descritiva completa e pré-processamento criterioso. Os resultados mostram que K-Means com $k=2$ oferece o melhor balanço entre qualidade dos clusters e interpretabilidade clínica, sendo capaz de separar parcialmente pacientes de baixo e alto risco metabólico sem utilizar o rótulo de diagnóstico. O problema definido foi parcialmente confirmado: existem agrupamentos naturais nos dados, mas a sobreposição entre perfis clínicos é considerável, refletindo a complexidade inerente ao diagnóstico de diabetes mellitus tipo

2. 9. Referências

SMITH, J. W. et al. Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus. Proceedings of the Annual Symposium on Computer Application in Medical Care, p. 261-265, 1988.

UCI Machine Learning Repository. Pima Indians Diabetes Database. Disponível em: <https://archive.ics.uci.edu/ml/datasets/diabetes>. Acesso em: jun. 2025.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.