

Classificação de Imagens com Redes Neurais Convolucionais (CNN) no Dataset CIFAR-10

Disciplina: Sistemas Inteligentes

Alunos: Diogo Rocha & Gabriel de Quadro

Contexto: Trabalho Prático – Classificação Multiclasse

1. Introdução

As Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNNs) representam o estado da arte na resolução de problemas de Visão Computacional. Devido à sua arquitetura projetada para preservar e mapear a topologia espacial dos pixels, as CNNs conseguem extrair automaticamente hierarquias de características (como bordas, texturas e formas complexas) sem a necessidade de engenharia manual de recursos (*feature engineering*).

Este relatório apresenta o desenvolvimento e a análise comparativa de três arquiteturas de redes convolucionais aplicadas a um subconjunto do dataset **CIFAR-10**. O escopo do experimento foi delimitado a quatro classes de transporte:

- **Airplane** (Avião)
- **Automobile** (Automóvel)
- **Ship** (Navio)
- **Truck** (Caminhão)

O principal objetivo deste estudo é investigar empiricamente como fatores como a profundidade da rede, o uso de regularização estocástica (*Dropout*) e rotinas automáticas de otimização impactam a capacidade de generalização e os fenômenos de *overfitting* ou *underfitting*.

2. Objetivos

Objetivo Geral

Desenvolver, avaliar e comparar o desempenho de três variações estruturais de Redes Neurais Convolucionais na tarefa de classificação multiclasse utilizando imagens coloridas.

Objetivos Específicos

- Implementar um pipeline robusto de carregamento, filtragem e normalização das imagens do CIFAR-10 para as quatro categorias escolhidas.
- Projetar e treinar três topologias com níveis crescentes de complexidade (Modelos 1, 2 e 3).
- Utilizar funções de perda, otimizadores e mecanismos de controle de convergência (*callbacks*) adequados.

- Analisar criticamente o comportamento das curvas de aprendizado (perda e acurácia) ao longo das épocas.
- Avaliar o desempenho detalhado do melhor modelo por meio de métricas estatísticas de precisão, revocação (*recall*), score F1 e matrizes de confusão.

3. Metodologia

Dataset e Pré-processamento

O CIFAR-10 é composto por imagens coloridas de **32 × 32 pixels** com três canais de cor (**RGB**). O fluxo de preparação dos dados seguiu as seguintes etapas cruciais:

1. **Filtragem de Amostras:** Isolamento exclusivo dos dados pertencentes às quatro classes-alvo (*Airplane, Automobile, Ship, Truck*), resultando em um conjunto perfeitamente balanceado de 1.000 imagens de teste/validação por classe (totalizando 4.000 amostras de validação).
2. **Codificação de Rótulos:** Reorganização dos rótulos categóricos textuais originais para índices numéricos inteiros no intervalo $[0, 3]$.
3. **Normalização de Escala:** Divisão do valor de cada pixel por 255.0, transpondo os canais de $[0, 255]$ para o intervalo numérico $[0, 1]$, reduzindo a instabilidade numérica dos gradientes durante a retropropagação.

Configurações de Treinamento

Os modelos foram construídos utilizando a biblioteca **TensorFlow / Keras** em ambiente Python. As definições fundamentais comuns foram:

- **Ativação Oculta:** Função retificadora **ReLU** (*Rectified Linear Unit*) em todas as camadas convolucionais e densas intermediárias.
- **Ativação de Saída:** Função **Softmax**, adequada para distribuir probabilidades exclusivas entre as 4 classes.
- **Função de Custo:** *Sparse Categorical Crossentropy*, compatível com alvos codificados numericamente de forma esparsa.
- **Otimizador:** **Adam**, devido ao seu mecanismo adaptativo de taxa de aprendizado baseado em momentos.

Mecanismos de Controle e Regularização

Para garantir a máxima eficiência computacional e proteger o treinamento contra sobreajuste (*overfitting*), três *callbacks* foram acoplados aos modelos:

- **EarlyStopping:** Monitoramento da perda de validação com encerramento antecipado das épocas caso o erro pare de decrescer de forma consistente.
- **ReduceLROnPlateau:** Redução dinâmica e multiplicativa da taxa de aprendizado ao detectar platôs na curva de validação, refinando a busca pelo mínimo global.
- **ModelCheckpoint:** Armazenamento persistente exclusivo da melhor versão dos pesos obtida ao longo de todo o histórico de épocas.

4. Arquiteturas Computacionais Propostas

- **Modelo 1 (Rasa / Baseline):** Constituído por 2 camadas convolucionais estruturadas de forma simples, alternadas por 2 camadas de subamostragem *MaxPooling*, finalizando em 1 camada densa totalmente conectada antes do bloco de saída. Projetado para avaliar a capacidade básica de extração linear de contornos.
- **Modelo 2 (Intermediária):** Expansão estrutural contendo 4 camadas convolucionais seguidas por *MaxPooling*. Introduz uma camada de regularização estocástica **Dropout de 40%** anterior à camada densa de 256 neurônios, visando quebrar a coadaptação de recursos.
- **Modelo 3 (Profunda):** Arquitetura altamente hierárquica construída com 6 camadas convolucionais profundas e 2 blocos de *MaxPooling*. Emprega duas camadas densas para representação abstrata de alto nível combinadas com um **Dropout severo de 50%** para maximizar a generalização em ambientes complexos.

5. Análise dos Resultados e Discussão

A avaliação experimental trouxe correções fundamentais às suposições iniciais de projeto, revelando dados exatos extraídos diretamente das métricas de validação de cada modelo.

Análise Evolutiva e Curvas de Aprendizado

Modelo 1

Com uma arquitetura simplificada e sem mecanismos agressivos de Dropout, o Modelo 1 atingiu rapidamente o seu limite estrutural. De acordo com a matriz de confusão, demonstrou boa capacidade empírica, mas deixou margem para confusões sistemáticas entre objetos estruturalmente parecidos de forma global (como veículos terrestres versus marítimos). Ele finalizou sua validação com uma acurácia real de aproximadamente **84%**.

Modelo 2

O Modelo 2 apresentou uma dinâmica interessante ao longo de suas 13 épocas. A análise dos gráficos de desempenho revela um comportamento clássico:

- **Curva de Acurácia (Modelo 2):** Enquanto a acurácia de treinamento escalou de forma contínua até próximo de 99%, a acurácia de validação estabilizou na faixa dos **87,5%**.
- **Curva de Perda (Modelo 2):** O gráfico de perda expõe de forma evidente a ocorrência de *overfitting*. A partir da época 6, a perda do treinamento continua em queda acentuada em direção a zero, enquanto a perda de validação sofre uma inflexão para cima, subindo de 0.32 para mais de 0.40 no término do treino. Isso mostra que o ganho marginal de acurácia em validação veio acompanhado de uma perda de calibração probabilística do modelo.

Modelo 3 (Melhor Modelo)

O Modelo 3 obteve a melhor performance global, encontrando o ponto ideal de convergência por volta da época 6, onde o **EarlyStopping** e o **ReduceLROnPlateau** atuaram de forma cirúrgica.

- **Curva de Acurácia (Modelo 3):** Apresenta curvas de treino e validação muito mais próximas e harmoniosas que o Modelo 2, atenuando as discrepâncias de

aprendizado e alcançando o topo dos testes práticos com uma acurácia final consolidada de **88,70%** e erro mínimo de perda de **0.3445**.

- **Curva de Perda (Modelo 3):** Embora a perda de validação apresente uma leve flutuação ascendente após a época 6, o Dropout de 50% seguiu a estabilidade estrutural da rede, permitindo que ela extraísse o maior coeficiente de discernimento de padrões entre as três topologias.

6. Comparação Quantitativa Consolidada

A tabela abaixo sintetiza rigorosamente os dados reais medidos ao final dos experimentos:

Modelo	Complexidade e Profundidade	Acurácia de Validação Final	Perda de Validação Mínima	Comportamento e Diagnóstico Técnico
Modelo 1	Baixa (2 camadas Conv)	$\approx 84,0\%$	≈ 0.4500	Viável e rápido, porém limitado na distinção de detalhes sutis de pixels.
Modelo 2	Média (4 camadas Conv)	$\approx 87,5\%$	≈ 0.3250	<i>Overfitting</i> visível a partir da época 6. Inflexão clara no gráfico de perda.
Modelo 3	Alta (6 camadas Conv)	88,70%	0.3445	Desempenho Superior. Melhor balanço de generalização e estabilidade.

7. Análise Detalhada do Modelo Escolhido (Modelo 3)

Para compreender as forças e fragilidades do melhor classificador desenvolvido por Diogo e Gabriel, analisamos minuciosamente o relatório de classificação e as matrizes de confusão geradas.

Relatório de Classificação Estatística

precision recall f1-score support

Airplane 0.8993 0.8660 0.8823 1000

Automobile	0.8583	0.9390	0.8968	1000
Ship	0.8786	0.8970	0.8877	1000
Truck	0.9176	0.8460	0.8803	1000
accuracy		0.8870		4000
macro avg	0.8884	0.8870	0.8868	4000
weighted avg	0.8884	0.8870	0.8868	4000

Diagnóstico por Categoria

1. **Automobile (Automóveis):** Obteve o maior índice de **Recall (93,90%)**. Isso indica que a rede é extremamente eficiente em mapear e encontrar os automóveis no dataset, deixando passar raríssimos falsos negativos (apenas 61 carros foram classificados incorretamente). Em contrapartida, sua precisão foi a menor (85,83%), indicando que outros objetos foram classificados como carros erroneamente.
2. **Truck (Caminhões):** Apresentou o comportamento inverso ao automóvel, registrando a maior **Precisão (91,76%)**. Quando o modelo afirma que uma imagem é um caminhão, a chance de acerto é elevadíssima. No entanto, o seu Recall foi o mais baixo (84,60%), gerando falsos negativos. A matriz de confusão explica isso: **92 caminhões foram erroneamente classificados como automóveis**, o que faz total sentido físico dada a semelhança morfológica entre eixos, rodas e contextos de estradas de ambos os veículos.
3. **Airplane e Ship (Aviões e Navios):** Ambas as classes mantiveram desempenhos sólidos e equilibrados com F1-Scores de **88,23%** e **88,77%**, respectivamente. O principal ponto de fricção identificado na matriz de confusão foi o erro cruzado entre eles: **82 aviões foram confundidos com navios e 51 navios foram confundidos com aviões**. Esse erro é justificado pelo padrão de fundo (*background*) das imagens: aviões no céu azul compartilham semelhanças cromáticas massivas com navios navegando em oceanos azuis, confundindo os filtros convolucionais intermediários da rede.

8. Conclusão

O estudo prático realizado na disciplina de Sistemas Inteligentes demonstrou com sucesso a aplicação e o refinamento de Redes Neurais Convolucionais para processamento de imagem colorida. O trabalho evidenciou de forma prática que o sucesso no treinamento de modelos profundos de *Deep Learning* vai muito além do simples empilhamento de camadas.

O comportamento do Modelo 2 comprovou que aumentar a capacidade computacional sem uma estratégia proporcional de regularização induz ao *overfitting*. Por outro lado, o **Modelo 3** provou ser a arquitetura mais robusta e madura: ao associar 6 camadas de filtros convolucionais a uma taxa rigorosa de Dropout de 50%, foi capaz de abstrair padrões complexos de bordas e texturas, alcançando uma sólida acurácia geral de **88,70%** na validação.

A análise das matrizes de confusão enriqueceu o trabalho ao comprovar que os erros cometidos pela Inteligência Artificial possuem forte correlação com a realidade visual (carros

vs. caminhões devido ao formato; aviões vs. navios devido ao fundo azul), validando o pipeline de aprendizado estruturado pelos autores.