

Universidade Federal de Santa Maria
centro de tecnologia

Trabalho Prático

Construção e Análise de Árvores de Decisão

Disciplina: sistemas inteligentes

Dataset: Heart Disease (Doença Cardíaca)

1. Introdução

Este relatório documenta o desenvolvimento e avaliação de modelos de Árvore de Decisão aplicados a um problema de classificação clínica, utilizando a biblioteca Scikit-Learn em Python. O objetivo central é investigar como a variação dos principais hiperparâmetros — **max_depth**, **criterion**, **min_samples_leaf** e **min_samples_split** — influencia o desempenho do classificador, medido por acurácia, precisão e recall. Ao final, os resultados são comparados e a melhor configuração é identificada e justificada.

2. Dataset

O dataset utilizado é o **Heart Disease Dataset**, inspirado no conjunto de dados do UCI Machine Learning Repository. Contém 100 amostras com 13 atributos clínicos de pacientes, tendo como variável alvo a presença (1) ou ausência (0) de doença cardíaca.

2.1 Atributos

Atributo	Tipo	Descrição
age	Inteiro	Idade do paciente (anos)
sex	Binário (0/1)	Sexo (0 = feminino, 1 = masculino)
cp	Categórico (0–3)	Tipo de dor no peito
trestbps	Inteiro	Pressão arterial em repouso (mmHg)
chol	Inteiro	Colesterol sérico (mg/dl)
fbs	Binário (0/1)	Glicemia em jejum > 120 mg/dl
restecg	Categórico (0–2)	Resultado do eletrocardiograma em repouso
thalach	Inteiro	Frequência cardíaca máxima atingida
exang	Binário (0/1)	Angina induzida por exercício
oldpeak	Float	Depressão do segmento ST pelo exercício
slope	Categórico (0–2)	Inclinação do segmento ST
ca	Inteiro (0–3)	Número de vasos coloridos por fluoroscopia
thal	Categórico (0–3)	Tipo de talassemia
target	Binário (0/1)	Diagnóstico — variável alvo

2.2 Pré-processamento

O dataset não apresentou valores ausentes, dispensando qualquer imputação. Todos os atributos já se encontravam em formato numérico, eliminando a necessidade de codificação de variáveis categóricas. A variável alvo possui distribuição perfeitamente balanceada (50 amostras por classe), o que descarta a necessidade de técnicas de reamostragem como SMOTE ou undersampling. Os dados foram divididos em 70% para treino e 30% para teste, com estratificação para preservar a proporção das classes em ambos os conjuntos.

3. Metodologia

Foram treinados 12 modelos de Árvore de Decisão, cada um com uma combinação distinta dos hiperparâmetros listados abaixo. Em cada experimento, os demais parâmetros foram mantidos fixos para isolar o efeito do parâmetro variado.

Hiperparâmetro	Valores Testados	Descrição
max_depth	3, 5, 10, None	Profundidade máxima da árvore. None = sem limite.
criterion	gini, entropy	Métrica de impureza para divisão dos nós.
min_samples_leaf	1, 5, 10	Número mínimo de amostras exigido em cada folha.
min_samples_split	2, 5, 10	Número mínimo de amostras para dividir um nó interno.

3.1 Métricas de Avaliação

Acurácia: proporção de predições corretas sobre o total de amostras. Confiável quando as classes são balanceadas, como no dataset utilizado.

Precisão: proporção de verdadeiros positivos entre todas as amostras preditas como positivas. Indica o quanto o modelo é confiável ao predizer presença de doença.

Recall (Sensibilidade): proporção de casos positivos reais corretamente identificados. Em contexto clínico, é a métrica mais crítica: um recall baixo significa deixar pacientes doentes sem diagnóstico.

4. Resultados

Modelo	max_depth	criterion	leaf	split	Acurácia	Precisão	Recall
M01	3	gini	1	2	0.8667	0.8235	0.9333
M02	5	gini	1	2	0.8667	0.8235	0.9333
M03	10	gini	1	2	0.8333	0.7778	0.9333
M04	None	gini	1	2	0.8333	0.7778	0.9333
M05	3	entropy	1	2	0.8667	0.8235	0.9333
M06	5	entropy	1	2	0.8667	0.8235	0.9333
M07	5	gini	5	2	0.8333	0.7778	0.9333
M08	5	gini	10	2	0.9000	0.8750	0.9333
M09	5	gini	1	5	0.8667	0.8235	0.9333
M10	5	gini	1	10	0.8667	0.8235	0.9333
M11	5	entropy	5	5	0.9000	0.8750	0.9333
M12	3	entropy	5	5	0.8667	0.8235	0.9333

* Linhas em verde: modelos com melhor desempenho (M08 e M11).




Figura 1 – Comparação de acurácia, precisão e recall entre os 12 modelos avaliados. Barras em verde indicam o(s) melhor(es) modelo(s).

4.1 Efeito Individual dos Hiperparâmetros




Figura 2 – Efeito do max_depth (criterion=gini, min_samples_leaf=1, min_samples_split=2).




Figura 3 – Efeito do criterion (max_depth=5, min_samples_leaf=1, min_samples_split=2).




Figura 4 – Efeito do min_samples_leaf (max_depth=5, criterion=gini, min_samples_split=2).




Figura 5 – Efeito do min_samples_split (max_depth=5, criterion=gini, min_samples_leaf=1).

5. Análise Comparativa dos Resultados

Dentre os 12 modelos avaliados, as melhores configurações foram o **Modelo M08** (`max_depth=5`, `criterion=gini`, `min_samples_leaf=10`, `min_samples_split=2`) e o **Modelo M11** (`max_depth=5`, `criterion=entropy`, `min_samples_leaf=5`, `min_samples_split=5`), ambos atingindo acurácia de 90,00%, precisão de 87,50% e recall de 93,33%, superando todos os demais. O principal fator responsável por esse desempenho superior foi o parâmetro **min_samples_leaf**: ao exigir um número mínimo maior de amostras em cada folha da árvore, o modelo é impedido de criar divisões muito específicas que capturam ruído do conjunto de treino, fenômeno conhecido como *overfitting*. Isso fica evidente ao comparar M02 (`leaf=1`, acurácia=86,67%) com M08 (`leaf=10`, acurácia=90,00%) mantendo os demais parâmetros fixos. Em relação ao **max_depth**, profundidades intermediárias (3 e 5) apresentaram desempenho superior às árvores muito profundas ou sem restrição (`depth=10` e `None`), que registraram acurácia de apenas 83,33%, confirmando que o excesso de profundidade leva ao *overfitting*. O parâmetro **criterion** (Gini ou Entropia) não produziu diferença significativa nas métricas para este dataset, o que é esperado em problemas de classificação binária balanceada, pois ambas as métricas tendem a gerar estruturas de árvore similares. Por fim, o **min_samples_split** demonstrou influência limitada: variar de 2 para 5 ou 10 não alterou os resultados quando os demais parâmetros permaneceram constantes, indicando que, no tamanho de dataset utilizado, o controle de regularização via `min_samples_leaf` já é suficiente. Em síntese, a configuração de melhor desempenho foi a do Modelo M08, por combinar uma profundidade moderada (`max_depth=5`) com forte regularização das folhas (`min_samples_leaf=10`), obtendo o melhor equilíbrio entre viés e variância. O alto recall de 93,33% é especialmente relevante no contexto de diagnóstico clínico, onde minimizar falsos negativos — ou seja, não deixar pacientes doentes sem diagnóstico — é prioritário.

6. Conclusão

Este trabalho demonstrou que a escolha cuidadosa de hiperparâmetros é fundamental para o bom desempenho de Árvores de Decisão. O parâmetro `min_samples_leaf` mostrou-se o mais impactante para a generalização do modelo, enquanto `max_depth` controla diretamente o risco de *overfitting*. A biblioteca Scikit-Learn mostrou-se uma ferramenta eficiente e flexível para experimentação sistemática com esses parâmetros. Como trabalho futuro, sugere-se a aplicação de validação cruzada *k-fold* para estimativas mais robustas das métricas, além do uso de métodos ensemble como Random Forest e Gradient Boosting, que tendem a superar árvores individuais em problemas similares.