

Trabalho Prático – Aprendizado Supervisionado com Seleção de Features e Otimização de Hiperparâmetros

Objetivo

Desenvolver um pipeline completo de Machine Learning utilizando um dataset real de livre escolha, aplicando técnicas de pré-processamento, seleção de atributos, treinamento de modelos, otimização de hiperparâmetros e análise de resultados.

O trabalho deve contemplar:

- Classificação Binária
- Classificação Multiclasse
- Regressão

Utilizando o mesmo dataset quando possível, ou datasets distintos devidamente justificados.

Etapas 1 – Escolha e Análise do Dataset

Selecione um dataset público contendo quantidade suficiente de amostras e atributos para justificar a aplicação de técnicas de seleção de features.

Fontes sugeridas:

- UCI Machine Learning Repository
- Kaggle
- OpenML
- Scikit-Learn Datasets

Apresente:

- Descrição do problema.
- Quantidade de amostras.
- Quantidade de atributos.
- Variável alvo.
- Distribuição das classes (quando aplicável).
- Possíveis problemas encontrados:
 - Valores ausentes.
 - Classes desbalanceadas.
 - Outliers.
 - Correlação elevada entre atributos.

Etapa 2 – Pré-processamento

Realize o tratamento necessário para os dados.

Inclua:

Tratamento de valores ausentes

Exemplos:

- Média
- Mediana
- Moda
- Remoção de registros

Codificação de variáveis categóricas

Exemplos:

- One-Hot Encoding
- Label Encoding

Normalização ou Padronização

Exemplos:

- StandardScaler
- MinMaxScaler
- RobustScaler

Justifique todas as escolhas realizadas.

Etapa 3 – Seleção de Features

Aplicar **uma única técnica de seleção de atributos**, escolhida pelo grupo.

Sugestões:

Métodos Filtro

- Correlação
- Mutual Information
- ANOVA F-Test
- Chi-Square

Métodos Wrapper

- Recursive Feature Elimination (RFE)

- Sequential Feature Selection

Métodos Embedded

- Lasso
- Random Forest Feature Importance
- XGBoost Feature Importance

O grupo deverá justificar a escolha da técnica utilizada.

Apresente:

- Quantidade inicial de atributos.
- Quantidade final de atributos selecionados.
- Ranking ou importância das features (quando disponível).
- Critério utilizado para definir as features escolhidas.

Além disso, compare os resultados dos modelos utilizando:

1. Todas as features disponíveis.
2. Apenas as features selecionadas.

Discuta se a seleção de atributos contribuiu para:

- Melhor desempenho.
- Redução de overfitting.
- Redução do tempo de treinamento.
- Melhor interpretabilidade do modelo.

Etapa 4 – Classificação com MLP

Desenvolver uma **Rede Neural Multicamadas (MLP)** para resolver um problema de classificação (binária ou multiclasse).

A implementação pode ser realizada utilizando:

- Scikit-Learn (MLPClassifier)
- TensorFlow/Keras
- PyTorch

O grupo deverá definir e justificar:

- Número de camadas ocultas.
- Número de neurônios por camada.
- Funções de ativação utilizadas.
- Otimizador escolhido.
- Taxa de aprendizado.

- Número de épocas.
- Tamanho do batch.

Avaliação

Para classificação binária

Apresentar:

- Accuracy
- Precision
- Recall
- F1-Score
- ROC-AUC
- Matriz de Confusão

Para classificação multiclasse

Apresentar:

- Accuracy
- Precision Macro
- Recall Macro
- F1 Macro
- Matriz de Confusão

Além disso, apresentar:

- Curva de aprendizado (loss por época).
- Evolução da métrica principal durante o treinamento.

Comparação (Opcional – Extra)

O grupo poderá comparar os resultados da MLP com um modelo clássico de Machine Learning, como:

- Random Forest
- SVM
- XGBoost
- Logistic Regression

Discutindo diferenças de desempenho e custo computacional.

Etapa 5 – Regressão com MLP

Desenvolver uma **Rede Neural Multicamadas (MLP)** para resolver um problema de regressão.

A implementação pode ser realizada utilizando:

- Scikit-Learn (MLPRegressor)
- TensorFlow/Keras
- PyTorch

O grupo deverá definir e justificar:

- Número de camadas ocultas.
- Número de neurônios.
- Funções de ativação.
- Otimizador.
- Taxa de aprendizado.
- Número de épocas.
- Batch size.

Avaliação

Apresentar:

- MAE
- MSE
- RMSE
- R^2

Além dos seguintes gráficos:

- Valores reais $\times$ valores preditos.
- Resíduos.
- Curva de aprendizado (loss por época).

Comparação (Opcional – Extra)

Opcionalmente, comparar a MLP com um modelo tradicional de regressão, como:

- Regressão Linear
- Ridge
- Lasso
- Random Forest Regressor
- XGBoost Regressor

Discutindo vantagens e desvantagens de cada abordagem.

Etapas 6 – Otimização de Hiperparâmetros com Optuna

Utilize o **Optuna** para otimizar os hiperparâmetros da Rede Neural Multicamadas (MLP) desenvolvida nas etapas anteriores.

O grupo deverá definir um espaço de busca para os hiperparâmetros e justificar as escolhas realizadas.

Exemplos de hiperparâmetros que podem ser otimizados

Arquitetura da Rede

- Número de camadas ocultas.
- Número de neurônios por camada.
- Funções de ativação.

Treinamento

- Learning Rate.
- Batch Size.
- Número de épocas.

Otimização

- Tipo de otimizador (Adam, SGD, RMSprop, entre outros).
- Momentum (quando aplicável).

Regularização

- Taxa de Dropout.
- Weight Decay (L2).

Resultados Esperados

Apresente:

- Espaço de busca utilizado.
- Quantidade de testes (trials) executados.
- Melhor conjunto de hiperparâmetros encontrado.
- Valor da função objetivo obtido pelo Optuna.
- Comparação entre:
 - Modelo original.
 - Modelo otimizado.

Discuta:

- Ganhos de desempenho obtidos.
- Impacto da otimização no tempo de treinamento.
- Principais hiperparâmetros encontrados pelo Optuna.

Comparação Opcional (Extra)

Caso o grupo implemente outro modelo além da MLP, poderá realizar também a otimização de seus hiperparâmetros e comparar os resultados com a rede neural.

Etapa 7 – Regularização e Análise de Overfitting

Investigue o comportamento da MLP em relação ao overfitting e underfitting.

O grupo deverá aplicar pelo menos **uma técnica de regularização** e analisar seus efeitos.

Técnicas sugeridas

Dropout

Inserção de camadas de Dropout para reduzir a dependência entre neurônios.

Weight Decay (Regularização L2)

Penalização dos pesos da rede durante o treinamento.

Early Stopping

Interrupção automática do treinamento quando não houver melhora no conjunto de validação.

Redução da Complexidade da Rede

- Menor número de camadas.
- Menor quantidade de neurônios.

Avaliação

Apresente:

- Curvas de treinamento e validação.
- Comparação entre:
 - Rede sem regularização.
 - Rede com regularização.

Analise:

- Existência de overfitting.
- Existência de underfitting.
- Impacto da regularização nas métricas finais.
- Impacto da regularização na capacidade de generalização da rede.

Discussão

Responder:

1. A rede apresentou sinais de overfitting?
2. Qual técnica de regularização foi utilizada?
3. Houve melhoria no desempenho em dados não vistos?
4. Qual estratégia apresentou melhor equilíbrio entre desempenho e generalização?

Comparação Opcional (Extra)

Caso outros modelos tenham sido implementados, discutir como esses modelos lidam com overfitting em comparação à MLP.